Get Talent – Challenge Semana 4

Construcción de un sistema RAG con APIs

Descripción

Se requiere implementar una API utilizando FastAPI que permita construir un sistema de **búsqueda semántica y generación de respuestas contextuales** basado en una arquitectura **RAG (Retrieval Augmented Generation)**. Este sistema trabajará con documentos de texto cargados por los usuarios, procesados para extraer embeddings y realizar búsquedas inteligentes.

La API manejará datos en memoria o almacenados localmente (sin necesidad de base de datos en esta versión) y utilizará servicios externos (APIs) para generar embeddings y respuestas.

Objetivos

Implementar los siguientes endpoints que permitan interactuar con los documentos y preguntas:

Santa Rosa 320 Piso 5 A
Teléfono +54(351)5693075
Email: info@piconsulting.com.ar
www.piconsulting.com.ar

1. **POST /upload**

- **Descripción:** Carga un nuevo documento en el sistema.

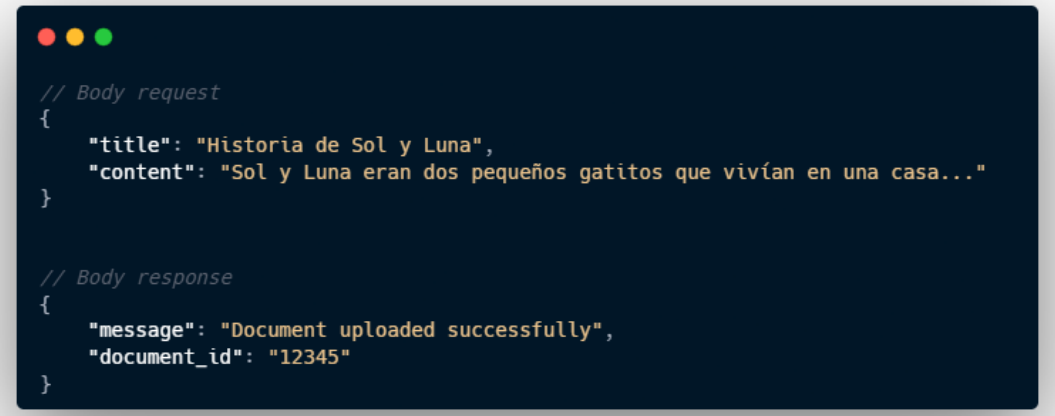

```
// Body request
{
    "title": "Historia de Sol y Luna",
    "content": "Sol y Luna eran dos pequeños gatitos que vivían en una casa..."
}


// Body response
{
    "message": "Document uploaded successfully",
    "document_id": "12345"
}
```

2. **POST /generate-embeddings**

- **Descripción:** Genera embeddings para un documento específico o para todos los documentos almacenados.

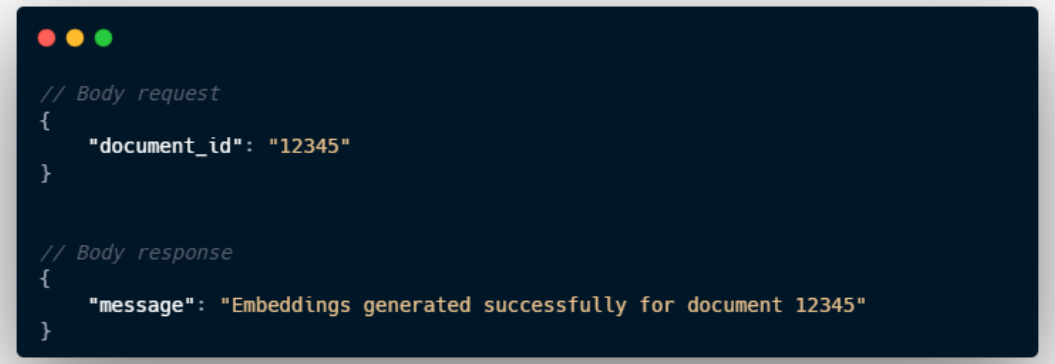

```
// Body request
{
    "document_id": "12345"
}


// Body response
{
    "message": "Embeddings generated successfully for document 12345"
}
```

3. **POST /search**

- **Descripción:** Busca los documentos más relvantes basados en una consulta.

Santa Rosa 320 Piso 5 A
Teléfono +54(351)5693075
Email: info@piconsulting.com.ar
www.piconsulting.com.ar

```
// Body request
{
    "query": "¿Qué aprendió Sol durante la tormenta?"
}


// Body response
{
    "results": [
        {
            "document_id": "12345",
            "title": "Historia de Sol y Luna",
            "content_snippet": "Sol aprendió a valorar la calma..."
        }
    ]
}
```

4. **POST /ask**

- **Descripción:** Genera una respuesta a una pregunta utilizando los documentos relevantes.

```
// Body request
{
    "question": "¿Qué aprendió Sol durante la tormenta?"
}

// Body response
{
    "answer": "Sol aprendió a valorar la calma y a no temer las tormentas."
}
```

Descripción de los campos

Datos de Entrada (Input)

1. **POST /upload**

Santa Rosa 320 Piso 5 A
Teléfono +54(351)5693075
Email: info@piconsulting.com.ar
www.piconsulting.com.ar

   a. **title:** Título del documento que se va a cargar (cadena de texto, obligatorio).
   b. **content:** Contenido del documento (cadena de texto, obligatorio).
2. **POST /generate-embeddings**
   a. **document_id:** Identificador único del documento para el cual se generarán los embeddings (cadena alfanumérica, obligatorio).
3. **POST /search**
   a. **query:** Consulta del usuario en lenguaje natural (cadena de texto, obligatorio).
4. **POST /ask**
   a. **question:** Pregunta formulada por el usuario en lenguaje natural (cadena de texto, obligatorio).

Datos de Salida (Output)

1. **POST /upload**
   a. **message:** Mensaje indicando que el documento se cargó correctamente (cadena de texto).
   b. **document_id:** Identificador único del documento cargado (cadena alfanumérica).
2. **POST /generate-embeddings**
   a. **message:** Mensaje indicando que los embeddings se generaron correctamente (cadena de texto).
   b. **document_id:** Identificador del documento para el cual se generaron los embeddings (cadena alfanumérica).
3. **POST /search**
   a. **results:** Lista de documentos relevantes para la consulta.

i. **document_id:** Identificador único del documento relevante (cadena alfanumérica).
ii. **title:** Título del documento relevante (cadena de texto).
iii. **content_snippet:** Fragmento del contenido relevante del documento (cadena de texto).
iv. **similarity_score:** Puntuación de relevancia con respecto a la consulta (número flotante entre 0 y 1).

4. **POST /ask**
    a. **question:** Pregunta formulada por el usuario (cadena de texto).
    b. **answer:** Respuesta generada basada en los documentos relevantes (cadena de texto).

Requisitos Técnicos

- **FastAPI:** Implementar la API para los endpoints especificados.
- **Embeddings API:** Utilizar un servicio externo (como Cohere o Hugging Face) para generar embeddings.
- **Modelo de Lenguaje:** Usar una API de un LLM (como Cohere para generar respuestas contextuales.
- **Persistencia:** Manejar los documentos y embeddings en memoria o en almacenamiento local (e.g. utilizando un vector store como ChromaDB o FAISS).
- **Validaciones y Errores:**
    - Validar datos de entrada (por ejemplo, que el título y el contenido no estén vacíos).
    - Manejar errores como documentos no encontrados (`404`) o problemas con servicios externos (`500`).